Департамент образования и науки города Москвы
Государственное автономное образовательное учреждение высшего образования города Москвы
«Московский городской педагогический университет»
Институт цифрового образования
Департамент информатики, управления и технологий

# ДИСЦИПЛИНА:

Проектный практикум по разработке ETL-решений

Вебинар 28.03.2025

Практическая работа на вебинаре

Выполнила: Шведова С.С., группа: АДЭУ-211

Преподаватель: Босенко Т.М.

Москва

#### Цели:

- 1. Спроектировать архитектуру
- 2. Создать даг с индивидуальным заданием
- 3. Создать файл sh

На рисунке 1 продемонстрирована верхнеуровневая архитектура.

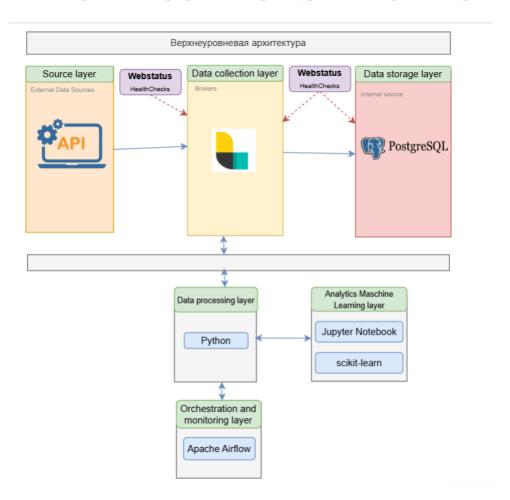


Рисунок 1. Верхнеуровневая архитектура

- 1. Слой источника данных (API Rocket): Использование API для сбора данных это распространенный подход.
- 2. Слой сбора данных (Logstash): Logstash это мощный инструмент для сбора, обработки и отправки данных. Он хорошо интегрируется с различными источниками данных и может обрабатывать данные в реальном времени.

- 3. Хранение данных (PostgreSQL): PostgreSQL это надежная реляционная база данных, которая поддерживает сложные запросы и транзакции. Она подходит для хранения структурированных данных.
- 4. Обработка данных (Python): Python обеспечивает обработку данных и является простым инструментом с множеством библиотек.
- 5. Аналитика и машинное обучение (Jupyter Notebook и scikitlearn): Jupyter Notebook предоставляет удобную среду для анализа данных и разработки моделей машинного обучения. Scikit-learn это мощная библиотека для машинного обучения, которая поддерживает множество алгоритмов.
- 6. Оркестрация и мониторинг (Apache Airflow): Apache Airflow это отличный инструмент для оркестрации рабочих процессов. Он позволяет планировать и управлять задачами, а также отслеживать их выполнение.

Эта архитектура позволяет эффективно собирать, хранить, обрабатывать и анализировать данные, обеспечивая гибкость и масштабируемость.

### Общая оценка экономической эффективности:

- 1. Снижение затрат на разработку: Данная архитектура снижает затраты на разработку благодаря использованию открытых технологий и интеграции между компонентами.
- 2. Улучшение производительности: Применение современного стека технологий позволяет значительно ускорить процессы сбора, обработки и аналитики данных.
- 3. Масштабируемость: Все компоненты могут быть масштабированы, что увеличивает их функциональность и позволяет приспособиться к изменяющимся требованиям бизнеса.

На рисунке 2 показана архитектура dag.

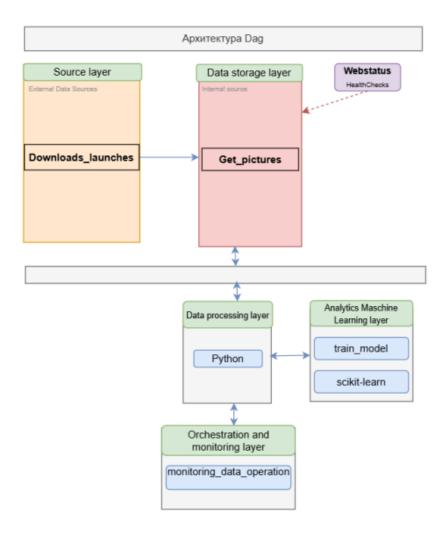


Рисунок 2. Архитектура дага

- 1. Слой источника данных (Downloads\_launches) Этот компонент отвечает за сбор данных. Он может представлять собой систему, которая загружает данные о запусках. Данные извлекаются и подготавливаются для передачи в следующий компонент.
- 2. Хранение данных (get\_pictures) Этот компонент, вероятно, отвечает за хранение изображений. После извлечения данных из Downloads\_launches, они сохраняются в get\_pictures.
- 3. Обработка данных (Python) Python используется для обработки данных, полученных из get\_pictures. Это может включать в себя очистку, преобразование и подготовку данных для анализа. С помощью библиотек,

таких как Pandas или NumPy, вы можете извлекать данные из get\_pictures, обрабатывать их и подготавливать для анализа.

- 4. Аналитика и машинное обучение (train\_model и scikit-learn) Этот компонент отвечает за обучение моделей машинного обучения с использованием scikit-learn. Он может включать в себя как обучение, так и оценку моделей. После обработки данных используется scikit-learn для создания и обучения моделей.
- 5. Оркестрация и мониторинг (monitoring\_data\_operation) Этот компонент отвечает за управление и мониторинг всего рабочего процесса. Он может включать в себя инструменты, такие как Apache Airflow, для автоматизации задач и отслеживания их выполнения. Создается DAG, который описывает последовательность задач, начиная с Downloads\_launches, затем переходя к get\_pictures, обработке данных с помощью Python, обучению модели и, наконец, мониторингу выполнения всех этих задач.

Все компоненты, использованные в данной архитектуре, являются бесплатными, тем самым снижая затраты компании.

Далее на рисунке 3 надо написать команду, которая вызывает утилиту cURL, используемая для передачи данных с использованием различных протоколов (в данном случае HTTP).

Рисунок 3. Команда curl -L

На рисунке 4 показан граф дага download\_rocket\_local, который успешно отработал.



Рисунок 4. Даг отработал

# На рисунке 5 показана диаграмма Ганта этого дага



Рисунок 5. Диаграмма Ганта

# На рисунке 6 показаны логи

# Рисунок 6. Логи

Затем нужно создать исполняемый файл export.sh, который автоматизирует выгрузку данных из контейнера в основную ОС данных, полученные в результате работы DAG в Apache Airflow (рисунок 7).



Рисунок 7. Исполняемый файл export.sh

Как можно увидеть на рисунке 8, все успешно скопировалось

```
dev@dev-vm:~/Downloads$ ./export.sh
Successfully copied 1.64MB to /home/dev/Downloads/data
The data has been uploaded
```

Рисунок 8. Файл sh успешно отработал

На рисунке 9 показан каталог data, где файлы перенеслись.

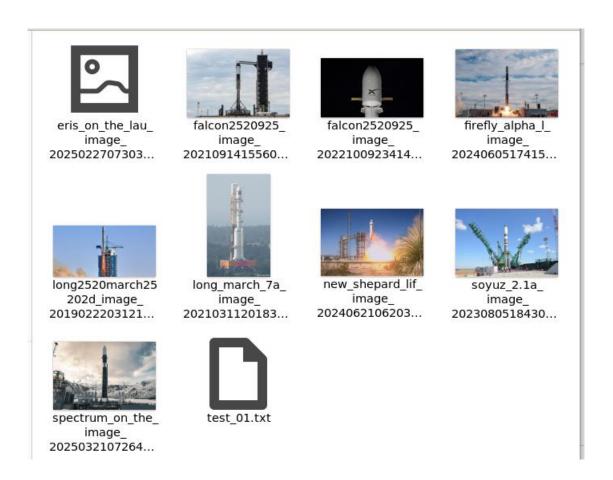


Рисунок 9. Файлы перенеслись

### Выполнение индивидуального задания

**Вариант 13.** Создать отчет по списку ракет и их изображений, используя данные JSON. Настроить загрузку изображений с альтернативных источников. Проанализировать, какие типы исключений нужно обрабатывать для успешной загрузки.

Созданный даг продемонстрирован на рисунке 10.

Рисунок 10. Код созданного дага

На рисунке 11 показано, что созданный даг отработал



Рисунок 11. Даг отработал

На рисунке 12 продемонстрирована диаграмма Ганта



Рисунок 12. Диаграмма Ганта

На рисунке 13 показаны логи отчета по списку ракет и их изображений, используя данные JSON (1 задание).

```
[2825-83-28, 15:86:38 UTC] {logging_mixin.py:188} INFO - Download Report: Successful downloads: 10, Failed downloads: 8. Check /opt/***/data/download_report.json for details.
```

Рисунок 13. Логи отчета

На рисунке 14 показан сам файл json

```
data > {} download_report.json >
           "successful downloads": [
 15
 16
17
                   "name": "Falcon 9 Block 5 | Starlink Group 6-80",
                   "url": "https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/falcon2520925_image_20221009234147.png"
 19
20
                   "name": "Eris-1 | Maiden Flight",
                   "url": "https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/eris_on_the_lau_image_20250227073032.jpg"
 22
 23
 24
25
26
27
28
                   "name": "Falcon 9 Block 5 | Starlink Group 11-13".
                   "url": "https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/falcon2520925_image_20221009234147.png"
                    'name": "Falcon 9 Block 5 | Fram2",
 29
30
                   "url": "https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/falcon2520925_image_20210914155606.jpeg"
 32
33
                   "name": "Long March 2D | Unknown Payload",
                   "url": "https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/long2520march25202d_image_20190222031211.jpeg"
 35
 36
                   "name": "Long March 6 | Unknown Payload",
 37
38
                   "url": "https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/long_march_6_image_20210709074933.jpg"
 39
                   "name": "Soyuz 2.1a | Soyuz MS-27",
 40
 41
                   "url": "https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/soyuz_2.la_image_20230805184309.jpg"
 42
 43
           'failed_downloads": []
```

Рисунок 14. Json файл

На рисунке 15 показана загрузка изображений с альтернативных источников (2 задание) при условии, что какое-то изображение не будет загружено.

```
[2025-03-28, 15:06:20 UTC] {standard_task_runner.pp;:87} IMFO - Bunning; ['**", 'tasks', 'run', 'download_rocket_local_report_alt', 'get_pictures', 'scheduled_2025-03-27700:00:00+00:00', '--job-id', '115', '-ro [2025-03-28, 15:00:20 UTC] {standard_task_runner.pp;:88} IMFO - Job 115: Subtask get_pictures
[2025-03-28, 15:00:22 UTC] {cask_instance; pp;:88} IMFO - Job 115: Subtask get_pictures
[2025-03-28, 15:00:22 UTC] {cask_instance; pp;:88} IMFO - Supring of vorters of
```

Рисунок 15. Загрузка изображений с альтернативных источников Функция работает следующим образом:

- Если функция download\_image вернула False (т.е., основное изображение не удалось загрузить), и если при этом в JSON-файле указан alternative\_image\_url, то функция download\_image вызывается повторно, но уже для альтернативного URL.
- Если загрузка альтернативного изображения прошла успешно, информация добавляется в отчет об успешных загрузках.

• Если загрузка альтернативного изображения также не удалась, выводится сообщение о том, что не удалось загрузить ни основное, ни альтернативное изображение.

Для обеспечения успешной загрузки изображений из различных источников (3 задание) необходимо обрабатывать следующие типы исключений:

- 1. requests.exceptions.RequestException:
- Описание: Этот класс является базовым для большинства исключений, возникающих при использовании библиотеки requests. Он включает в себя исключения, связанные с проблемами сети, НТТР-ошибками и другими общими проблемами при выполнении НТТР-запросов.
- Почему нужно обрабатывать: Перехват этого исключения позволяет обрабатывать широкий спектр проблем, связанных с отправкой и получением HTTP-запросов.
  - 2. OSError (или IOError в старых версиях Python):
- Описание: это исключение возникает при ошибках, связанных с операционной системой, таких как проблемы с файловой системой, недостаток прав доступа и т.д.
- Почему нужно обрабатывать: при сохранении загруженных изображений в файлы могут возникать проблемы с доступом к файловой системе или нехваткой места на диске.
  - 3. json.JSONDecodeError:
- Описание: это исключение возникает, если возникают проблемы с декодированием JSON-данных из файла или URL.
  - Почему нужно обрабатывать: если формат JSON недействителен.
  - 4. Exception:
- Описание: это общий класс исключений, который перехватывает все остальные, более специфичные исключения.

• Почему нужно обрабатывать: В блоке except имеет смысл обрабатывать исключение, чтобы перехватывать любые другие непредвиденные исключения.

На рисунке 16 продемонстрирована загрузка json файла в Google Colab

```
import json
[1] with open('download_report.json') as json_file:
             data = json.load(json_file)
    → {'successful_downloads': [{'name': 'Spectrum | Maiden Flight',
           'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/spectrum on the image 20250321072643.jpeg'}, {'name': 'Long March 7A | Unknown Payload',
           'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/long march 7a image 20210311201838.jpg'}, {'name': 'Firefly Alpha | FLTA006 (Message in a Booster)',
             'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/firefly_alpha_l_image_20240605174156.jpeg'},
           {'name': 'Falcon 9 Block 5 | Starlink Group 6-80',
'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/falcon2520925 image 20221009234147.png'},
           {'name': 'Eris-1 | Maiden Flight',
             'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/eris on the lau image 20250227073032.jpg'},
            {'name': 'Falcon 9 Block 5 | Starlink Group 11-13',
             url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/falcon2520925 image 20221009234147.png'},
           {'name': 'Falcon 9 Block 5 | Fram2',
             'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/falcon2520925 image 20210914155606.jpeg'},
           {'name': 'Long March 2D | Unknown Payload',
'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/long2520march25202d image 20190222031211.jpeg'},
           {'name': 'Long March 6 | Unknown Payload',
'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/long march 6 image 20210709074933.jpg'},
           {'name': 'Soyuz 2.1a | Soyuz MS-27', 'url': 'https://thespacedevs-prod.nyc3.digitaloceanspaces.com/media/images/soyuz 2.1a image 20230805184309.jpg'}],
          'failed_downloads': []}
[13] failed_downloads = pd.DataFrame(data['failed_downloads'])
         failed_downloads
    ₹
   [9] successful_df = pd.DataFrame(data['successful_downloads'])
         successful df
    ₹
                                                    name year
                                 Spectrum | Maiden Flight 2025
                        Long March 7A | Unknown Payload 2021
          2 Firefly Alpha | FLTA006 (Message in a Booster) 2024
                      Falcon 9 Block 5 | Starlink Group 6-80 2022
          3
                                     Eris-1 | Maiden Flight 2025
                   Falcon 9 Block 5 | Starlink Group 11-13 2022
                                  Falcon 9 Block 5 | Fram2 2021
          6
                        Long March 2D | Unknown Payload 2019
                        Long March 6 | Unknown Payload 2021
```

Рисунок 16. Загрузка json файла

На рисунке 17 показано график распределения успешных запусков по годам. Как можно заметить, среди всех успешных запусков больше всего было в 2021 году.





Рисунок 17. График распределения успешных запусков по годам

#### Выводы:

- 1. Автоматизация загрузки и обработки изображений (и других типов данных) позволяет снизить затраты на ручной труд. Вместо того, чтобы сотрудники вручную загружали и обрабатывали каждое изображение, автоматизированная система может выполнять эту задачу быстрее и с меньшими затратами.
- 2. Эта автоматизированная система работает круглосуточно, что позволяет значительно повысить производительность и сократить время выполнения задач.
- 3. Автоматизированная система настроена на выполнение определенных правил и проверок, что позволяет снизить количество ошибок, связанных с человеческим фактором.